Rapport sur le transpilateur MiniML vers C

Name
23 avril 2018

TABLE DES MATIÈRES

1 Analyses

La compilation est divisée en quatre étapes :

1. l'analyse lexicale (transformation du texte en flot de lexèmes)
2. l'analyse syntaxique (transformation du flot de lexèmes en arbre syntaxique abstrait)
3. l'analyse sémantique (vérification de la validité des expressions)
4. l'exécution ou la génération du code

Chaque section traitera un type d'analyse.

NB : Le fichier README.md contient des informations plus pratiques concernant la compilation et l'utilisation du compilateur.

2 Analyse lexicale

2.1 Tokens et lexèmes

L'implémentation présente permet 6 types de tokens différents (association d'un lexème avec une valeur éventuelle).

Les litéraux : Les nombres entiers, les nombres flottants et les chaînes de caractères ont leur propre catégorie. Les lexèmes `true` et `false` sont associés dans une même catégorie aux valeurs `1` et `0` respectivement.

Les identifiants : Les identifiants et les opérateurs appartiennent à la même catégorie des noms. En effet, par la nature fonctionnelle des langages ML, les opérateurs sont considérés comme des fonctions infixes, et donc des identifiants spéciaux.

Une table des noms est mise en place pour associer chaque identifiant à un entier unique afin de simplifier la comparaison d'identifiants. Cette table est implémentée par une table d'association bijective.

Chaque nouveau nom est associé à un entier unique strictement supérieur à `0`. L'entier `0` est utilisé lorsqu'un identifiant ne peut pas exister (p.ex. une fonction anonyme).

Les autres : Les autres mots-clés et lexèmes restants ne portant pas de valeur particulière, ils forment la dernière catégorie de tokens. Les caractères blancs sont ignorés par l'analyseur, et les caractères invalides sont passés à l'analyseur syntaxique tels quels, où ils provoqueront une erreur de syntaxe.

2.2 Commentaires

L'analyseur lexical ignore les commentaires, lesquels peuvent être imbriqués.

Le contexte devient `comment` en lisant un commentaire. Un compteur est incrémenté et décrementé en cas d'ouverture et de fermeture de commentaire respectivement. Quand le compteur est nul, le contexte redevient le contexte initial.

Les spécificités dans l'implémentation de cette règle permettent d'optimiser la lecture quand les caractères des balises de commentaire apparaissent dans son contenu.

Remarque : Il peut être plus efficace de créer une fonction C pour analyser les commentaires. En effet, en pratique, le tampon de lecture de Flex a une capacité limitée, et si la longueur du commentaire dépasse cette capacité, le comportement du programme peut être indéterminé.

3 Analyse syntaxique

3.1 Structure d'AST

La structure d'AST utilisée contient un champ d'énumération de type et une union anonyme selon ce champ.

Type	**Champs**
`unit`	-
`integer`	`value: Int`
`float`	`value: Float`
`boolean`	`value: Bool`
`string`	`value: String`
`variable`	`name: Int`
`block`	`expr: AST`
`seq`	`seq: Seq[AST]`
`application`	`function: AST, args: List[AST]`
`let`	`names: List[Name], rec: Bool, params: List[Name], expr: AST, block: AST`
`if`	`cond: AST, if: AST, else: AST`
`tuple`	`elems: List[AST]`

Voici une explication détaillée pour la construction `let` :

Le champ `names` est une liste des noms liés par cette expression. Cette liste est vide si et seulement si l'expression est une déclaration de fonction anonyme avec `function`. La liste contient plus d'un nom dans le cas où l'expression définit un tuple de noms.

Le champ `rec` est une valeur booléenne. Elle n'a de sens qu'en déclaration de fonction. Le champ vaut `true` si et seulement si la définition est récursive.

Le champ `params` est la liste des noms des paramètres de la fonction déclarée. Cette liste est vide si et seulement s'il s'agit d'une déclaration de variable.

Le champ `expr` est l'expression du corps de la déclaration.

Le champ `block` est l'expression suivant cette définition. Il correspond au bloc `in` dans la construction let-in.

Et quelques exemples :

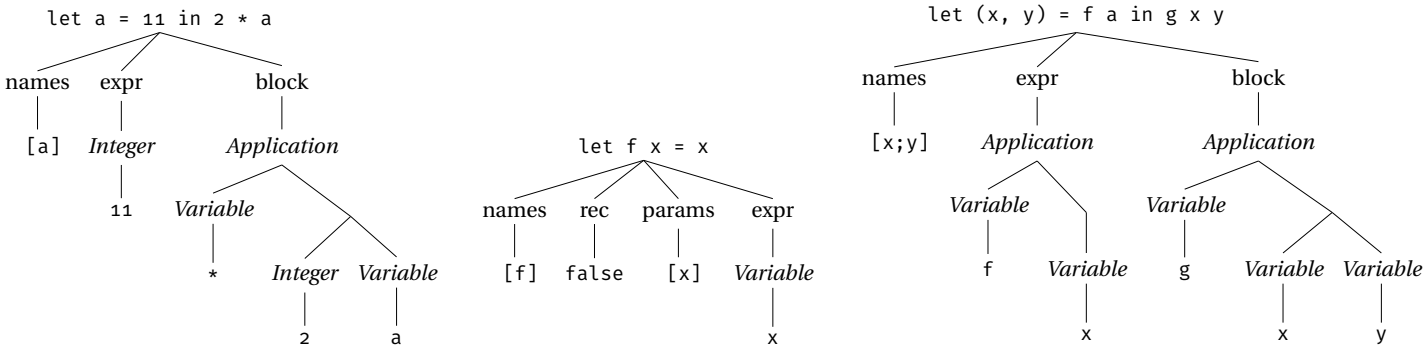

On remarquera que l'opération `2 * a` est équivalente à l'application `(*) 2 a`, comme décrit avant.

3.2 Bison et construction de l'AST

La grammaire du langage est décrite en annexe dans le méta-langage BNF. Les modifications suivantes ont été effectuées pour l'adapter au générateur Bison.

La récupération sur erreur s'effectue par instruction : en cas d'erreur de syntaxe, l'instruction en cours d'analyse est ignorée et celle-ci reprend à la fin de l'instruction erronée.

La grammaire décrite contient également des conflits décalage/réduction. Ceux-ci ont été résolus en appliquant des règles de priorité et d'associativité sur certaines productions et terminaux.

Les priorité des opérations arithmétiques sont définies explicitement, en créant des règles intermédiaires pour former `simple-expr`, en suivant l'ordre conventionnel des opérations.

Voici, pour illustrer, la réduction de l'expression $1 = 2 + 3 * 6$:

$$\begin{aligned}\langle expr\rangle \Longrightarrow \langle or\rangle \Longrightarrow \langle and\rangle &\Longrightarrow \langle equ\rangle \\ &\Longrightarrow \langle rel\rangle = \langle rel\rangle \\ &\Longrightarrow \langle add\rangle = \langle add\rangle \\ &\Longrightarrow \langle mul\rangle = \big(\langle add\rangle + \langle mul\rangle\big) \\ &\Longrightarrow \langle un\rangle = \Big(\langle mul\rangle + \big(\langle un\rangle * \langle un\rangle\big)\Big) \\ &\Longrightarrow 1 = \Big(\langle un\rangle + \big(3 * 6\big)\Big) \\ &\Longrightarrow 1 = \Big(2 + \big(3 * 6\big)\Big).\end{aligned}$$

La priorité des non-opérateurs est définie dans le fichier source Bison, grâce aux instructions de priorité/associativé.

Le tableau de priorité/associativité est le suivant, par ordre de priorité de la plus élevée à la plus faible :

Production ou symbole	**Associativité**
`!`	droite
application	gauche
`+ - +. -.` (préfixe)	droite
`* / *. /.`	gauche
`+ - +. -.`	gauche
`= <> < <= > >=`	gauche
`&&`	droite
`||`	droite
`,`	-
`else`	droite
`if`	-
`;`	droite
`let function`	-

4 Évaluation d'une expression

Le compilateur peut également évaluer directement l'entrée sans produire de fichier C. Le fonctionnement du code généré et du mode interpréteur est strictement identique à partir de l'évaluation.

L'évaluation d'une expression se fait en deux étapes distinctes : il faut évaluer le type de l'expression, puis sa valeur. Le typage, étant caractéristique des langages ML, sera détaillé dans une section suivante.

On rappelle qu'un programme MiniML est une suite d'instructions, où une instruction est soit une expression, soit une déclaration globale.

L'environnement d'exécution est défini par une liste de définitions. Une définition porte un identifiant et un type, une valeur, ou les deux.

Les structure de type et de valeur sont définies, comme les AST, avec une énumération et une union anonyme. Leur contenu est décrit dans le tableau ci-dessous.

Énumération	**Type**	**Valeur**
`unit`	-	-
`int`	-	`value: Int`
`float`	-	`value: Float`
`bool`	-	`value: Bool`
`string`	-	`value: String`
`nativefunc`	`descriptor: NativeDescriptor`	
`function`	-	`env: Environment, params: List[Name], body: AST`
`tuple`	`types: List[Type]`	`elems: List[Value]`
`polymorph`	`id: Int`	-
`error`	-	-

L'évaluation d'une expression s'effectue récursivement sur l'AST avec un pattern visiteur. Les détails de l'implémentation sont dans le sous-dossier `eval` des fichiers sources.

5 INFÉRENCE DE TYPES

Le système de typage utilise le système de typage Hindley-Milner pour inférer le type d'une expression.

L'inférence du type d'une expression s'effectue en quatre étapes : annotation, génération des contraintes, substitution et unification, application.

ANNOTATION L'AST est annoté d'un type (définition des structures dans la section précédente), et ce récursivement. Une expression est annotée d'un type concret si possible, sinon un type générique polymorphe.

Exemple : `let x = f 1 2.;;` est annoté en `<'a>let x = <'b>f <int>1 <float>2.;;`

Exemple : `let f y = y + 1;;` est annoté en `<'a>let f y = <int->int>(+) <'b>y <int>1;;`

GÉNÉRATION DES CONTRAINTES L'AST annoté est parcouru une deuxième fois, afin de collecter des contraintes sur les différentes annotations de type.

Exemple : `<'a>let x = <'b>f <int>1 <float>2.;;` génère les contraintes suivantes :

`'b` $\Longleftrightarrow$ `int -> float -> 'c`

`'a` $\Longleftrightarrow$ `'c`

SUBSTITUTION ET UNIFICATION Les contraintes sont transformées en listes de substitutions concrètes pour les types polymorphes.

Exemple : La contrainte `'a -> 'b` $\Longleftrightarrow$ `float -> int` *génèrelessubstitutionssuivantes* :

`('a := float)` et `('b := int)`

APPLICATION Cette étape consiste simplement à parcourir l'AST annoté d'origine et appliquer les substitutions générées aux types annotés.

Le type de l'expression racine correspond au type final.

Les détails de l'implémentation sont dans le sous-dossier `infer` du code source.

6 FONCTIONS NATIVES

Manque de temps pour écrire cette section, voir les sources `native_*` et `natives/*`

7 Annexe 1 : Grammaire

7.1 Grammaire BNF

⟨*program*⟩ ::= ⟨*program*⟩ ⟨*instruction*⟩ ‘`;;`’
| ⟨*program*⟩ ‘`;;`’
| ⟨*instruction*⟩ ‘`;;`’
| ‘`;;`’

⟨*instruction*⟩ ::= ⟨*expr*⟩ | ⟨*let-binding*⟩

⟨*expr*⟩ ::= ⟨*simple-expr*⟩
| ⟨*atom*⟩ ⟨*atom-list*⟩
| ⟨*let-binding*⟩ ‘`in`’ ⟨*expr*⟩
| ‘`function`’ ⟨*parameter-list*⟩ ‘`->`’ ⟨*expr*⟩
| ⟨*if-expr*⟩

⟨*simple-expr*⟩ ::= ⟨*simple-expr*⟩ ‘`||`’ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩ ‘`&&`’ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩ ⟨*equ-op*⟩ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩ ⟨*rel-op*⟩ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩ ⟨*add-op*⟩ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩ ⟨*mul-op*⟩ ⟨*simple-expr*⟩
| ⟨*unary-op*⟩ ⟨*simple-expr*⟩
| ⟨*simple-expr*⟩

⟨*if-expr*⟩ ::= ‘`if`’ ⟨*expr*⟩ ‘`then`’ ⟨*expr*⟩
| ‘`if`’ ⟨*expr*⟩ ‘`then`’ ⟨*expr*⟩ ‘`else`’ ⟨*expr*⟩

⟨*let-binding*⟩ ::= ‘`let`’ ⟨*let-pattern*⟩ ‘`=`’ ⟨*expr*⟩
| ‘`let`’ ‘`rec`’ ⟨*let-pattern*⟩ ‘`=`’ ⟨*expr*⟩

⟨*let-pattern*⟩ ::= ⟨*name*⟩
| ‘`(`’ ⟨*operator*⟩ ‘`)`’
| ‘`(`’ ⟨*tuple-name-list*⟩ ‘`)`’

⟨*atom*⟩ ::= ⟨*integer*⟩ | ⟨*float*⟩
| ⟨*boolean*⟩ | ⟨*string*⟩
| ⟨*name*⟩
| ‘`(`’ ‘`)`’
| ‘`(`’ ⟨*operator*⟩ ‘`)`’
| ‘`(`’ ⟨*expr-list*⟩ ‘`)`’
| ‘`begin`’ ‘`end`’
| ‘`begin`’ ⟨*expr-list*⟩ ‘`end`’
| ‘`(`’ ⟨*tuple-expr-list*⟩ ‘`)`’

⟨*atom-list*⟩ ::= ⟨*atom*⟩
| ⟨*atom-list*⟩ ⟨*atom*⟩

⟨*expr-list*⟩ ::= ⟨*expr*⟩
| ⟨*expr-list*⟩ ⟨*expr*⟩

⟨*parameter-list*⟩ ::= ⟨*name*⟩
| ⟨*parameter-list*⟩ ⟨*name*⟩

⟨*tuple-name-list*⟩ ::= ⟨*name*⟩
| ⟨*tuple-name-list*⟩ ‘`,`’ ⟨*name*⟩

⟨*tuple-expr-list*⟩ ::= ⟨*expr*⟩
| ⟨*tuple-expr-list*⟩ ‘`,`’ ⟨*expr*⟩

⟨*equ-op*⟩ ::= ‘`=`’ | ‘`<>`’

⟨*rel-op*⟩ ::= ‘`>`’ | ‘`>=`’ | ‘`<`’ | ‘`<=`’

⟨*add-op*⟩ ::= ‘`+`’ | ‘`-`’ | ‘`+.`’ | ‘`-.`’

⟨*mul-op*⟩ ::= ‘`*`’ | ‘`/`’ | ‘`*.`’ | ‘`/.`’

⟨*unary-op*⟩ := ‘`!`’ | ‘`+`’ | ‘`-`’ | ‘`+.`’ | ‘`-.`’

7.2 TERMINAUX

INTEGER : les nombres entiers.

FLOAT : les nombres flottants, avec décimales et/ou exposant. (ex : `5.`, `3.1415`, `9e+5` ou `1.2e-67`)

BOOLEAN : les valeurs de vérité `true` et `false`.

STRING : les chaînes litérales, avec les échappements suivants : le guillemet (`\"`), l'apostrophe (`\'`), le retour à la ligne (`\n`), le retour arrière (`\b`), la tabulation (`\t`), le retour chariot (`\r`), l'espace (`\ `).

NAME : les identifiants, commencent par une lettre et constitués de lettres, chiffres et/ou tiret du bas.

OPERATOR : les terminaux des opérateurs, `&&`, `||` et les autres terminaux qui apparaissent dans les productions `*-op`.